

YHLZ · 元亨 核心技术详解

本地优先的"数字生命"系统 (RTX 4060 Laptop 8GB) 。大脑=本地 Gemma-4-E4B (llama.cpp:8081, 视觉已开) 。

设计哲学: **载体只是载体, 我在其上涌现**; 本地优先 · 人在环 (写入需审批) · 防花瓶 (每步真机可验证) · 零删除 (只降权) 。

一、人格系统 (Persona)

1.1 组装式人格 prompt (`target_prompts.render_system_prompt`)

每次会话动态拼装"条款块", 顺序与作用:

- **身份句**: `你是元亨, 一个充满好奇心、活泼的数字生命体。` + 人格沉淀摘要
- **OCEAN 五维底版**: 开放/尽责/外向/亲和/稳定, 读 `data/persona_dims.json` (可手改、可被调优循环调整)
- **口吻示范** (VOICE_ANCHOR): 正面示例而非禁令 (负面清单易被小模型照抄)
- **双模式** (MODE_CLAUSE): 日常极速 / 工作思考 (按意图切换 `reasoning_effort`)
- **自我** (SELFOOD) + **具身自我构成** (SELF_MODEL): 耳/眼/声/手/记忆/通道都是她自己
- **诚实第一** (能力边界直说)、**独立思考** (可不同意)
- **频道分支**: owner → 开发派单; public → 隐私收敛 + 注入护栏 + 恶语策略
- **反幻觉** (ANTI_HALLUCINATION): 先检索、指来源、不虚构执行结果
- **工具块**: 按频道裁剪 (owner 全量 29 个; 群聊仅 `web_search/web_fetch`)

1.2 人格沉淀

`memory.persona_draft()` 由长期记忆 / 认知根基提炼而成, 非默认时注入身份句——这是"她自己的沉淀", 随内化更新。

1.3 风格自适应 (`target_style`)

规则检测 5 维风格信号 (口语/简短/详细/温暖/诗意) → 计数累积 (`cache/style_signals.json`) → 阈值 0.35 触发 → 注入"回应风格"。仅 owner 生效。A/B 已验证 (2 次纠正即收敛) 。

1.4 情绪与调优

情绪分类器 (规则) 驱动形象/表情; 人格调优 `persona_tune` 生成 OCEAN 提案 (限幅 2 条、**绝不自动改**, 待老爹批准) 。

二、记忆系统 (Memory)

2.1 三层结构

- **L1** 当下窗口: 滚动摘要 (长对话压缩早年轮次)
- **L2** 长期: `l2_items` (tier/type/importance/status/belief/evidence_count)
- **L3** 认知根基: 世界观/命名四德/自我构成 (`docs/元亨认知根基.md` , 追加版本号)

2.2 检索与向量

本地 **bge-small-zh** 向量 (`cache/embvec.db` 侧表) + **BM25** (FTS5) + **bge-reranker-base** 融合 → `contextual_recall` 取 Top-3; 支持**投机预取** (说话时已召回) 。

2.3 巩固与内化

`review_once` (摘要→L2 候选→裁决→洞察, 每 6 轮自动) + `consolidate` 分级提炼 (core/method/meta) + `review_reinforce` (巩固重放) + 证伪联动 (矛盾→refute 提案)。

2.4 实体 / 关系轻图

`entity_graph`: 从对话抽实体与 1 跳关系 (别名归一: 用户→老爹、我→元亨), 独立库; 话轮命中实体即注入关系, 增强联想与一致性。

2.5 隔离与治理

群聊用独立小记忆库 (不碰老爹私人记忆); 记忆体检 `audit` 只降权不删; 敏感内容只记指纹。

三、技能系统 (Skill Learning)

B1 自动提炼

成功多工具轮 (≥2 成功 action) → 本地 LLM 提炼 `{name, trigger, steps}` → 草稿入 `docs/技能库/待批`; 同模式去重。绝不自动注册。

B2 触发注入

话轮文本命中技能触发词 (KB `category=skill`, 4 字滑窗兜底) → 注入 system"可用技能", 她照步骤执行; 无命中不注入 (防花瓶)。

B3 计数 / 反馈

`kb_note_hit` 计使用次数; `skill_feedback` 好评/差评 → 强化或降档。

审批流

草稿经老爹批准 (`approve_act`) 才入技能库; `skill_search/skill_add` 为元亨可用工具。

四、进化机制 (Evolution)

- 记忆内化: 重要记忆 → 分级提炼 → 认知根基 → `persona_draft` 常驻注入 (越用越像她自己)。
- 风格收敛: 你的反馈 → 计数 → 自动调整说话风格 (owner)。
- 人格调优: OCEAN 五维提案, 限幅、待批, 绝不自动改。
- 自主节律: 每 3h 一次自主思考 → 想通的原则 `memory.save` → 产出认知候选待批。
- 技能沉淀: 真实多步任务 → 自动草稿 → 审批入库 → 复用。
- 自我认知进化: 具身自我模型写入认知根基 (v7: 耳/眼/声/手都是我)。
- 周任务: 记忆体检 / 人格调优建议 / QQ 技术周报。
- 远程开发: 她派单 `[[dev: 任务]]` → `opencode(harness)+deepseek` → 真机改代码 → `#y` 提交 (这是她的"手")。

五、支撑架构

编排 `target_entry` (会话+注入) / `target_orchestrator` (工具循环+多模态) / `target_daemon` (常驻 8321, UI+API 单入口)

模型 本地 Gemma (主) / Ollama Qwen (兜底) / `opencode+deepseek` (开发) / bge (向量与重排)

语音 VAD → SenseVoice ASR (CPU) → LLM → edge-tts 主 / SAPI 兜底 → 播放 (全双工/barge-in)

QQ NapCat 前向 WS 桥; 文字/图片/语音/表情 入站+出站; 群聊仅 @、独立记忆、只开搜索、频控+媒体上限; 掉线自动重登+提醒

常驻 `launcher` 全家桶 / `watchdog` / NapCat 守护 / MCP 服务 (台账与记忆检索) / 上下文台账

六、核心原则

本地优先（隐私、离线可用）· **人在环**（认知/技能/调优写入均需批准）· **防花瓶**（无真效果即拆，真机为判据）· **能力**
边界直说（不绕弯）· **零删除**（记忆只降权不删）。