

三层记忆架构技术设计文档（上篇）

一、架构总览

1.1 设计目标

本架构旨在为本地部署的大语言模型（LLM）构建一套完整的记忆系统，实现从瞬时感知到长期认知的全周期记忆管理。架构融合 TiMem 时序分层、Hermes 记忆治理、Hy-Memory 双系统加工三大主流框架优势，形成覆盖“写入→存储→检索→遗忘→人格转化”全周期的闭环设计。

1.2 三层架构定义

记忆层级	核心定位	生命周期	存储形式	对应 TiMem 层级
瞬时记忆 (Ephemeral Memory)	维持当前对话连贯性的热记忆	会话结束即清空	直接复用 LLM 上下文窗口	L1 原始片段
中期记忆 (Short-term Memory)	近期可复用的事实、事件、短期偏好	30-90 天，按规则衰减淘汰	结构化文本+元数据（时间、重要性、关键词）	L2 会话摘要+L3 每日总结
长期记忆 (Long-term Memory)	跨时间稳定的核心事实、人格特征、长期偏好	永久留存，仅冲突/主动删除时更新	核心事实文本+关键词标签+人格向量	L4 每周趋势+L5 人格画像

1.3 架构核心设计原则

- 复杂度感知召回：简单问题检索浅层，复杂问题检索深层。
- 双系统异步处理：System1 实时处理 + System2 深度分析。
- 记忆即数据：所有记忆条目结构化，支持版本控制与回溯。
- 隐私优先：全部本地部署，数据不出本机。

二、瞬时记忆链路设计

2.1 写入链路

- 所有当前会话的对话历史实时写入 LLM 上下文窗口（Context Window），无额外加工。
- 采用滑动窗口（Sliding Window）策略管理容量。

2.2 容量管理策略

- 当对话超出上下文窗口上限时，采用摘要压缩（Summary Compression）策略。
- 保留最近 3-5 轮完整对话，将早期对话压缩为结构化摘要。
- 摘要保留核心实体（Entities）、结论（Conclusions）、待办事项（Action Items）。
- 不使用直接截断（Naive Truncation），避免关键信息丢失。

2.3 读取链路

- LLM 生成回复时直接以全量上下文为输入，无需额外检索。
- 前缀缓存（Prefix Cache）优化：将高频系统级指令、用户核心偏好固定在上下文头部，提升缓存命中率。

2.4 流转触发

- 会话结束或用户主动关闭对话时，触发中期记忆摘选流程（Memory Extraction Pipeline）。

三、中期记忆链路设计

3.1 写入链路

3.1.1 触发时机

- 会话结束或上下文溢出前强制触发，不阻塞实时对话（非阻塞式写入）。

3.1.2 记忆摘选（Memory Extraction）

- 调用轻量 LLM（如 Qwen2.5:7B）从原始对话中提取原子化事实（Atomic Facts）。
- 过滤闲聊（Chitchat）、问候（Greeting）、重复内容（Redundant Content）。
- 仅保留有跨会话复用价值的信息：用户偏好（Preferences）、重要决策（Decisions）、待办事项（Action Items）、关键事实（Key Facts）。

3.1.3 记忆条目结构

每条中期记忆包含以下元数据字段：- **content**：内容摘要，一句话概括核心信息。- **type**：类型枚举（fact/preference/event/decision）。- **importance**：重要性评分（1-10），由 LLM 评估。- **keywords**：关键词列表，用于精确检索。- **entities**：涉及的实体/人名/地点。- **created_at**：创建时间戳。- **last_accessed**：最后访问时间戳。- **access_count**：访问次数。- **decay_score**：衰减分数，初始值为 1.0。

3.2 检索链路（五层混合召回架构）

3.2.1 查询分析器（Query Analyzer）

通过轻量 LLM 判断查询类型（Query Type）：- **exact**（精确查询）：包含具体名称、编号、日期等精确信息。- **temporal**（时序查询）：涉及时间线、趋势、变化。- **semantic**（语义查询）：模糊的语义查询。- **complex**（复杂推理查询）：需要跨时间段推理。

输出结果包括：目标层级（Target Layers）、时间约束（Time Constraint）、关键实体（Key Entities）。

3.2.2 多通道并行检索（Multi-Channel Parallel Retrieval）

通道一：BM25 关键词检索 - 基于词频-逆文档频率（TF-IDF）变体算法。- 匹配精确查询：设备编号、具体日期、专有名词。- 中文场景使用 jieba 分词。

通道二：向量语义检索（Vector Semantic Retrieval） - 使用 BGE-M3 编码记忆内容为语义向量。- 匹配模糊语义查询：同义表达、概括性查询、口语化表述。- 存储于 ChromaDB 向量数据库。

通道三：时序检索（Temporal Retrieval） - 基于时间戳过滤时间范围。- 支持时间约束查询：“上周提到的事”、“最近 3 天的记录”。- SQLite FTS5 全文检索支持。

3.2.3 结果融合层

倒数排名融合（RRF, Reciprocal Rank Fusion） - 公式： $RRF_score(d) = \sum 1/(k + rank_i(d))$ ，其中 k 为经验常数（通常取 60）。- 忽略原始分数量纲，仅按排名位置融合多通道结果。- 消除不同检索通道的量纲差异。

时序加权 (Temporal Weighting) - 使用指数衰减函数: $\text{weight} = 0.5^{(\text{days_old} / \text{half_life})}$ 。 - 近期记忆权重更高。 - 半衰期可根据场景调整 (常规场景 7 天, 长期项目 30 天)。 - 综合得分 = RRF 分数 $\times$ 时序权重 $\times$ 重要性加权。

3.2.4 精排层 (Reranking)

- 使用 Cross-Encoder 重排序模型 (如 BAAI/bge-reranker-v2-m3)。
- 将查询和每条候选记忆配对, 做细粒度的相关性判断。
- 输出 Top3-5 条注入当前对话上下文。

3.3 流转触发规则

- **晋升触发**: 同一中期记忆被多次检索 ($\text{access_count} \geq 3$) / 重要性评分 ≥ 8 / 反复出现在不同会话中 $\rightarrow$ 触发长期记忆晋升流程。
- **遗忘触发**: 记忆衰减分数低于阈值且重要性 $\leq 3 \rightarrow$ 触发遗忘归档流程。

四、记忆路由机制 (Memory Routing)

4.1 核心原理

- LLM 充当“记忆分拣员” (Memory Router), 每次有新信息产生时, 对信息做分类决策。
- 通过函数调用 (Function Calling) + 结构化输出 (Structured Output) 实现。
- 决策输出为 JSON 格式, 包含: tier (目标层级)、memory_type (记忆类型)、importance (重要性)、reason (分类理由)、structured_data (结构化数据)。

4.2 路由分类规则

- **L0 (上下文窗口)**: 当前对话直接需要的临时信息, 无需持久化。
- **L1 (工作记忆)**: 当前任务的中间状态、临时结论, 任务结束即可丢弃。
- **L2 (会话记忆)**: 本次会话中的重要事实、决策、事件, 会话级保留。
- **L3 (长期记忆)**: 跨会话有价值的信息, 包括用户偏好、稳定事实、反复出现的模式、重要事件、技能与 SOP。

4.3 双系统异步处理架构

- **System1 (实时通道)**: 毫秒级处理, 负责写原始痕迹、抽事实、更新画像。
- **System2 (后台通道)**: 秒~分钟级处理, 负责抽心智模型、构建知识网络、记忆巩固、矛盾消解。
- 通过异步消息队列 (Message Queue) 解耦两条通道, 避免深度分析阻塞主对话。

五、长期记忆链路设计

5.1 存储结构

5.1.1 结构化事实库 (Structured Fact Base)

- 存储跨时间稳定的核心信息: 用户身份、核心经历、重要决策、长期偏好。
- 每条包含: 文本内容 + 关键词标签 + 更新时间 + 访问次数。
- 支持关键词精确匹配和语义模糊匹配检索。

5.1.2 人格画像库 (Personality Profile Base)

- 存储用户的性格、思想、沟通风格等抽象特征。
- 采用大五人格模型 (Big Five / OCEAN 模型) 量化:
 - 开放性 (Openness): 1-5 分
 - 尽责性 (Conscientiousness): 1-5 分
 - 外向性 (Extraversion): 1-5 分

- 宜人性 (Agreeableness): 1-5 分
- 神经质 (Neuroticism): 1-5 分
- 同时包含: 沟通风格描述、决策偏好、核心价值观、给 AI 的回复建议。

5.2 检索链路

- 事实库仅在查询相关历史信息时按需召回, 采用关键词+语义双通道检索。
- 人格画像每次对话时直接作为 System Prompt 的一部分全量注入, 无需检索。

5.3 晋升触发机制

- 每周或每积累 20 条中期记忆时自动触发巩固任务 (Consolidation Task)。
- 读取近期所有中期记忆, 调用 LLM 提炼出跨时间稳定的事实、规律、偏好。
- 写入长期记忆事实库。

5.4 冲突处理机制

- 不直接删除旧记忆, 执行版本控制 (Version Control)。
- 旧记忆标记为[已失效, 生效区间: 起始日期~失效日期]。
- 新记忆标记为[当前有效, 生效起始: 当前日期]。
- 检索时默认只召回“当前有效”版本, 支持回溯历史版本。
- 定期巩固任务中, 合并同一实体的多个失效版本为一条演化轨迹记录 (Evolutionary Trail)。

三层记忆架构技术设计文档（下篇）

六、遗忘机制设计 (Forgetting Mechanism)

6.1 中期记忆遗忘规则

6.1.1 时间衰减模型

本架构采用 FSRS (Free-Spaced Repetition Scheduler) 幂律衰减模型作为中期记忆的生命周期管理核心，确保记忆强度随时间推移与访问频率动态调整。

核心公式： $S=(1\times t/S)^{-w_{20}}$

其中，S 代表记忆强度 (Stability)，t 为距上次访问的时间间隔。被检索到的记忆将提升稳定性 S，未被访问的记忆强度则遵循幂律逐渐下降。

综合权重计算公式： $=\times\times\times$

各因子定义与计算逻辑：

- 1. 重要性 (Importance)：初始赋值区间为 [1,10]，在记忆写入阶段由 LLM 根据内容语义价值进行评估。
- 2. 时间衰减 (Time Decay)：采用指数衰减函数 $e^{-(\lambda\times\Delta)}$ 。衰减系数 λ 依据记忆保护等级差异化配置：
 - 高保护： $\lambda=0.005/$
 - 标准保护： $\lambda=0.02/$
 - 低保护： $\lambda=0.05/$
- 3. 访问增强 (Access Boost)：每次检索命中即重置衰减时钟，并累积稳定性系数： $1+0.2\times_count$ 。
- 4. 身份一致性 (ICS, Identity Coherence Score)：量化评估记忆内容与用户核心身份画像的契合度。高 ICS 记忆将获得额外的保护权重，防止核心人设相关记忆被误删。

6.1.2 阈值淘汰策略

基于计算出的综合权重，执行分级处置策略：

权重区间	处置动作	说明
Weight > 0.5	保留	维持当前状态，正常参与检索排序。
0.1 < Weight ≤ 0.5	降权观察	降低检索优先级，标记为“待观察”，不立即移除。
0.01 < Weight ≤ 0.1	冷存储归档	移出热检索索引，存入冷存储区，仅保留历史可追溯性。
Weight ≤ 0.01	触发蒸馏	进入长期记忆转化流程（详见第七节），尝试提取模式价值。

6.1.3 冲突替换机制

当新写入记忆与已有记忆存在语义冲突时（例如：用户声明“我不吃辣了”，而旧记忆为“喜欢吃辣”），系统不执行物理删除，而是采用版本化失效标记：

- 1. 旧记忆状态标记为 [OBSOLETE]（已失效）。
- 2. 新记忆建立指向旧记忆的演化链接。

3. 支持基于时间轴的偏好回溯，确保历史上下文在必要时仍可被检索和解释。

6.2 长期记忆遗忘规则

6.2.1 保护等级分类

长期记忆实施严格的分级保护策略，防止核心资产流失：

保护等级	记忆类型	遗忘策略	典型示例
白名单（永不遗忘）	用户身份、核心安全规则	豁免一切自动遗忘与衰减机制	“用户是靖远电厂技术主管”
高保护（仅冲突替换）	核心偏好、重要决策	仅在用户主动纠正或出现明确逻辑矛盾时替换	“用户偏好数据驱动的决策方式”
标准保护（衰减+归档）	阶段性事实、中期偏好	遵循时间衰减模型，低于阈值后归档至冷存储	“用户上个月关注锅炉检修”
低保护（主动淘汰）	一次性事件、临时状态	快速衰减，定期执行清理任务	“用户某天提到想去某个地方”

6.2.2 遗忘执行策略

- 白名单强制保护：**所有标记为 `protected=True` 的记忆（含身份、核心偏好、关键决策）物理隔离于遗忘扫描之外。
- 仅更新不删除原则：**长期记忆默认视为永久资产。仅在用户显式指令删除或新事实构成逻辑互斥时，才触发旧条目替换。
- 定期巩固任务：**每周自动运行 Consolidation Job，合并语义重复的长期记忆条目，执行实体对齐，消除存储冗余。

6.2.3 防误伤防御机制

- 只读记忆区（Read-Only Memory Zone）：**在长期记忆库中划分物理或逻辑隔离区，该区域数据对遗忘算法完全不可见。
 - 矛盾消解优先：**当检测到信息冲突时，优先触发版本控制流程，标记新旧版本共存，保留完整的认知演化轨迹，而非简单覆盖。
-

七、长期记忆→人格提示词转化机制

7.1 主流参考方案

方案来源	转化方式	核心特征
PersonaVLM (CVPR 2026 Highlight)	大五人格量化 + 指数移动平均动态更新	每轮对话推断临时性格评分, 利用 EMA 融合进长期画像, 实现动态对齐。
MindMemory	心智理论 (ToM) 驱动的人格建模	从情景记忆和语义记忆中主动推断用户心理状态与深层人格特质。
Soul Spec	结构化身份文件 (不可变)	身份定义与记忆架构物理隔离, 每次会话重新注入, 防止记忆噪声污染人格。
四维蒸馏模型	程序性知识+互动风格+记忆经历+性格价值观	将数字痕迹解构为四个正交维度, 分别蒸馏为可执行的 Prompt 指令。

7.2 渐进式人格蒸馏架构

7.2.1 转化层级流程

graph LR; A[长期记忆原始条目
数百~数千条] -->|每月定期蒸馏| B(模式特征提取
行为/沟通/决策); B -->|累积融合| C[人格画像
200-500 tokens]; C -->|每次对话注入| D[System Prompt]; D -->|指导生成| E[LLM 回复风格与内容];

7.2.2 人格画像结构 (Persona Profile)

维度	内容说明	示例
维度一：性格量化	基于大五人格模型 (OCEAN), 每项 1-5 分	O:4, C:5, E:2, A:3, N:1
维度二：沟通风格	一句话描述交互偏好	“偏好简洁直接的技术表述, 不喜欢冗余客套, 倾向先给结论再展开。”
维度三：决策偏好	一句话描述决策逻辑	“注重数据支撑, 决策前收集多方信息, 偏谨慎但不拖延。”
维度四：核心价值观	2-3 个最高优先级价值锚点	["效率优先", "安全合规", "技术可靠性"]
维度五：回复行为指令	给 LLM 的具体执行约束	“优先给出数据支撑的结论; 避免过度客套; 涉及安全问题时主动提醒风险; 技术讨论时默认对方有专业背景。”

7.3 动态更新机制

7.3.1 更新触发条件

- **时间触发**：每月 1 日自动执行。
- **事件触发**：每积累 50 条新中期记忆时自动触发。

7.3.2 指数移动平均（EMA）融合

为平衡画像的适应性与稳定性，采用自适应 α 系数：

$$(\text{Profile})[] = \alpha \times (\text{Inference})[] + (1 - \alpha) \times (\text{Profile})[]$$

- **早期交互阶段（< 30 天）**： $\alpha=0.3$ 。新证据权重较高，画像快速适应用户初始特征。
- **稳定阶段（> 90 天）**： $\alpha=0.1$ 。新证据权重降低，画像趋于稳态，有效过滤偶发性异常行为干扰。

7.3.3 冲突处理与防御

1. **偏差阈值**：当新推断的性格维度与旧画像偏差 >1.5 分时，禁止直接覆盖。
2. **观察期机制**：标记该维度为 Under Observation，需连续 3 次独立推断确认后才正式更新。
3. **核心身份锁定**：职业、基本背景等核心身份一旦确立，除非用户主动声明变更，否则不受自动更新逻辑影响。

7.4 遗忘→转化的闭环设计

长期记忆的遗忘与人格转化是同一闭环的两个出口，遵循“**记忆可逝，模式永存**”原则：

```
graph TD
    A[长期记忆条目] --> B{权重衰减扫描}
    B -->|权重仍高| C[保留，继续参与检索]
    B -->|权重降低| D[降权，减少检索优先级]
    B -->|权重极低| E[归档前触发蒸馏]
    E -->|有模式价值| F[提取模式特征 → 融入人格画像]
    E -->|无模式价值| G[直接归档，不提取]
```

核心原则：具体的事件记忆可以被遗忘，但蕴含其中的行为模式、思维习惯和价值观必须被蒸馏为人格画像的一部分，以更简洁、更稳定的形式持续塑造模型行为。

八、完整闭环总览

8.1 全链路数据流

```
graph TD
    A[瞬时记忆<br/>上下文窗口] -->|会话结束| B[中期记忆<br/>LLM摘选，30-90天]
    B -->|五层混合检索| C[注入上下文]
    B -->|时间衰减+阈值淘汰+冲突替换| D{反复出现/高重要性?}
    D -->|Yes| E[长期记忆<br/>永久存储]
    D -->|No| F[冷存储/归档]
    E -->|权重衰减扫描| G{状态判定}
    G -->|高权重| H[保留，参与检索]
    G -->|低权重| I[归档前蒸馏]
    I -->|有模式价值| J[融入人格画像]
    I -->|无模式价值| K[安全淘汰]
    G -->|冲突| L[版本控制，新旧共存]
    J -->|每月定期巩固| M[人格画像<br/>200-500 tokens]
```

8.2 核心设计哲学

记忆系统的终极目标不是“记住一切”，而是“理解这个人”。

事实会过期，偏好会改变，事件会褪色。但一个人稳定的性格特征、思维方式和核心价值观，应当从海量记忆中被提炼出来，成为模型持久认知的基础。遗忘不是系统的缺陷，而是系统进化的必要手段；通过遗忘，我们完成了从“数据记录”到“人格认知”的跃迁。

8.3 主流参考方案索引

方案名称	来源	核心贡献
TiMem	上海 AI Lab	五层时序记忆树，复杂度感知召回，SOTA 长程记忆准确率 75.3%。
Hermes	开源社区	Write-Manage-Read 循环，引入记忆审查与晋升机制。
MemOS	开源社区	图谱结构记忆节点，跨会话检索 P99 延迟降至 45ms。
PersonaVLM	CVPR 2026 Highlight	大五人格量化，双阶段协作流，实现动态人格对齐。
Hy-Memory	腾讯混元	双系统异步处理（System 1 实时 + System 2 深度），平衡响应速度与认知深度。
Soul Memory	2026 开源	身份锚点隔离 + 时序衰减，架构层面物理隔离身份与经历。
MindMemOS	华为诺亚方舟	Dreaming 离线整理机制，自动识别重复、冲突及演化关系。
MemoryBank	arXiv 2023	艾宾浩斯遗忘曲线驱动的记忆强度衰减，奠定生物启发式遗忘基础。